

DeepFactory: Sistema Multiagentes para Gestão e Otimização de Produção Industrial

Rodrigo Drummond Macedo, Antônio Neto

Deeptera Sistemas Inteligentes
{antonio, rodrigo}@deeptera.com

Arley Henrique Duque

Framework Digital
arleyduque@frwk.com.br

Sandro Jerônimo de Almeida

Pontifícia Universidade Católica de Minas Gerais
sandro.j@pucminas.br

RESUMO

A indústria de manufatura enfrenta desafios de eficiência e integração, mesmo com avanços em Indústria 4.0, IoT e análise de dados. Apesar da disponibilidade de ferramentas para diferentes etapas do processo produtivo, a gestão permanece fragmentada, resultando em decisões descoordenadas, gargalos e baixa adaptabilidade. Diante disso, este trabalho propõe o DeepFactory, uma plataforma multiagente que integra planejamento de materiais, sequenciamento, execução, manutenção e controle de qualidade. A plataforma combina modelos de otimização, aprendizado de máquina e visão computacional, incluindo cobertura de estoque, sequenciamento via programação inteira mista, manutenção preditiva e inspeção automatizada, coordenados por agentes de IA. Como diferencial, destaca-se a integração estruturada desses paradigmas em uma arquitetura orientada por estágios, com geração de insights acionáveis. Como relato de sistema, este trabalho apresenta um caso de uso ilustrativo em cenário simulado de manufatura farmacêutica, demonstrando a aplicabilidade da arquitetura proposta.

PALAVRAS CHAVE. Manufatura Inteligente, Sistemas Multiagentes, Otimização de Produção, Inteligência Artificial, Indústria 4.0.

Tópicos: Pesquisa Operacional com Inteligência Artificial e Pesquisa Operacional na Indústria

ABSTRACT

Industrial manufacturing faces challenges related to efficiency and integration, even with advances in Industry 4.0, the Internet of Things (IoT), and data analytics. Despite the availability of tools for different stages of the production process, management remains fragmented, resulting in uncoordinated decisions, bottlenecks, and low adaptability. In this context, this work proposes DeepFactory, a multi-agent platform that integrates material planning, production scheduling, execution, maintenance, and quality control. The platform combines optimization models, machine learning, and computer vision techniques, including inventory coverage analysis, mixed-integer programming-based scheduling, predictive maintenance, and automated inspection, all coordinated

by AI agents. As a key contribution, the system provides a structured integration of these paradigms within a stage-oriented architecture, enabling the generation of actionable insights. As a system-oriented study, this work presents an illustrative use case in a simulated pharmaceutical manufacturing scenario, demonstrating the applicability of the proposed architecture.

KEYWORDS. Smart Manufacturing, Multi-Agent Systems, Production Optimization, Artificial Intelligence, Industry 4.0.

Paper topics: Artificial Intelligence in Operations Research and Operations Research in Industry

1. Introdução

As empresas de produção e manufatura enfrentam desafios recorrentes que exigem altos níveis de eficiência para a manutenção da competitividade. Observa-se um processo acelerado de digitalização, impulsionado por iniciativas como Indústria 4.0 [Zhong et al., 2017], Internet das Coisas (IoT) [Yang et al., 2019] e o uso crescente de dados no chão de fábrica. Nesse contexto, torna-se cada vez mais viável coletar, processar e analisar informações ao longo de todo o ciclo produtivo, desde o planejamento até a execução e avaliação de desempenho. Paralelamente, avanços em áreas como otimização matemática, aprendizado de máquina e inteligência artificial ampliam significativamente o potencial de suporte à decisão em ambientes industriais.

Apesar desse avanço tecnológico, transformar esse conjunto de soluções em sistemas efetivamente integrados e aplicáveis à operação cotidiana ainda representa um desafio relevante. Na prática, a gestão da produção permanece fragmentada entre diferentes camadas e sistemas — como Material Requirements Planning (MRP), Enterprise Resource Planning (ERP) e Manufacturing Execution Systems (MES) — que operam de forma parcialmente desacoplada. Essa fragmentação resulta em decisões locais descoordenadas, dificultando a adaptação a eventos dinâmicos e levando à formação de gargalos operacionais, aumento de custos e perda de eficiência global.

Além disso, embora técnicas avançadas de otimização, aprendizado de máquina e visão computacional tenham demonstrado resultados promissores em problemas específicos da manufatura, sua aplicação integrada ao longo de todo o processo produtivo ainda é limitada. Em particular, há uma lacuna na coordenação dessas abordagens em arquiteturas unificadas que permitam não apenas a análise isolada de cada estágio, mas também a geração de decisões consistentes e contextualizadas em nível sistêmico.

Neste contexto, este trabalho apresenta o *DeepFactory*, uma plataforma multiagente integrada voltada à gestão e suporte à otimização de sistemas produtivos de ponta a ponta. A solução integra diferentes estágios do processo de manufatura — planejamento de materiais, sequenciamento da produção, execução, manutenção e controle de qualidade — por meio da combinação de modelos de otimização, aprendizado de máquina e visão computacional, coordenados por agentes inteligentes.

Diferentemente de abordagens tradicionais, o *DeepFactory* incorpora agentes de IA capazes de consumir informações contextualizadas de múltiplos estágios. Esses agentes utilizam modelos de linguagem (LLMs) para gerar insights acionáveis e apoiar a tomada de decisão. Essa integração permite automatizar análises operacionais e apoiar a tomada de decisão, ao sintetizar informações complexas em recomendações interpretáveis. Além disso, a consideração conjunta de diferentes dimensões do sistema produtivo — como estoque, capacidade produtiva, manutenção e qualidade — possibilita análises mais profundas e decisões mais robustas, reduzindo a miopia associada a otimizações locais.

O sistema é estruturado como uma arquitetura modular orientada por estágios, na qual cada etapa do processo produtivo integra: (i) uma camada de visualização com métricas operacionais, (ii) modelos analíticos específicos — incluindo previsão de demanda (SARIMAX), sequenciamento via programação inteira mista (MIP), manutenção preditiva (XGBoost) e inspeção por visão computacional (YOLO + ByteTrack) — e (iii) agentes especializados responsáveis por interpretar os resultados e apoiar a tomada de decisão de forma proativa ou sob demanda, via interface conversacional.

Como forma de ilustrar a aplicabilidade da proposta, o trabalho apresenta um caso de uso em um cenário simulado de manufatura farmacêutica, ilustrando o funcionamento integrado do sistema ao longo de todo o ciclo produtivo. O trabalho é também uma oportunidade de relato de casos de uso de IA Generativa em cenários industriais.

Este trabalho está organizado da seguinte forma: a Seção 2 apresenta trabalhos relacionados aos sistemas multiagente, aprendizado de máquina e otimização matemática aplicados à indústria. A Seção 3 descreve o DeepFactory, incluindo sua arquitetura e modelos. A Seção 4 apresenta o estudo de caso. Por fim, a Seção 5 traz as conclusões e trabalhos futuros.

2. Trabalhos Relacionados

Os Sistemas Multiagente (SMA) têm sido amplamente utilizados para modelar ambientes distribuídos compostos por entidades autônomas capazes de perceber, decidir e atuar de forma coordenada, [Wooldridge, 2009; Russell e Norvig, 2010]. No contexto industrial, essa abordagem se mostra particularmente relevante diante da crescente complexidade dos sistemas produtivos e das demandas associadas à Indústria 4.0, permitindo maior adaptabilidade a eventos dinâmicos.

Na manufatura, SMA vêm sendo explorados em aplicações como coordenação de recursos, controle distribuído e integração com gêmeos digitais. Abordagens recentes têm investigado a incorporação de agentes inteligentes em arquiteturas baseadas em *digital twins*, bem como sua integração com tecnologias de Internet das Coisas para controle e replanejamento dinâmico, [Greis et al., 2025; Nie et al., 2022; Vyskočil et al., 2023]. Esses avanços evidenciam uma tendência em direção a sistemas produtivos mais autônomos e distribuídos. No entanto, tais soluções frequentemente tratam de forma isolada os componentes de otimização, aprendizado e tomada de decisão, limitando sua aplicação em cenários industriais integrados.

No âmbito da Pesquisa Operacional, problemas de planejamento e sequenciamento da produção têm sido extensivamente estudados, com destaque para o *Job Shop Scheduling Problem* (JSSP) e suas variações. Trabalhos recentes exploram tanto métodos exatos quanto heurísticas e abordagens híbridas para otimização de métricas como *makespan*, [Momenikorbekandi e Kalganova, 2025; Moser et al., 2022; Naderi et al., 2023]. Essas técnicas apresentam elevada robustez e eficiência na modelagem de problemas complexos. Entretanto, em geral, são aplicadas de forma isolada, sem integração com mecanismos inteligentes de interpretação de dados ou suporte adaptativo à decisão em tempo real.

Paralelamente, o uso de técnicas de *Aprendizado de Máquina* (ML) na manufatura tem crescido significativamente, especialmente em aplicações como manutenção preditiva, previsão de demanda e controle de qualidade. Métodos baseados em aprendizado supervisionado têm sido amplamente utilizados para detecção de falhas, classificação de eventos e redução de tempo de inatividade, [Tsallis et al., 2025; Abidi et al., 2022; Elkateb et al., 2024]. Na previsão de demanda, modelos de ML contribuem para maior acurácia no planejamento produtivo, [Sistla et al., 2024], enquanto técnicas de visão computacional e *deep learning* têm sido empregadas na inspeção automatizada de qualidade, [Zhou et al., 2022; Islam et al., 2024]. Apesar dos ganhos operacionais, essas abordagens são, em sua maioria, implementadas como soluções modulares e independentes, com pouca integração entre si e com os demais níveis do sistema produtivo.

Mais recentemente, a literatura também tem explorado o potencial da Inteligência Artificial Generativa no contexto industrial, especialmente no suporte à decisão e na automação de processos cognitivos, [Doanh et al., 2023]. Além disso, a integração com softwares tradicionais da indústria demonstra grande potencial, como forma de controlar e interagir com um sistema exclusivamente via interface conversacional [Neto et al., 2025].

Diante desse cenário, observa-se uma lacuna na integração de diferentes paradigmas ao longo do processo produtivo. Nesse contexto, este trabalho apresenta um relato de sistema que busca explorar a integração de modelos de otimização, aprendizado de máquina e inteligência artificial em uma arquitetura multiagente unificada.

3. DeepFactory

O DeepFactory é um sistema estruturado em estágios que representam as principais fases do processo produtivo em uma indústria de manufatura. A plataforma foi concebida para abordar problemas recorrentes do chão de fábrica, tais como gestão de cobertura de estoque, sequenciamento de produção em múltiplas linhas, manutenção preditiva de equipamentos, controle de qualidade por inspeção de vídeo e análise de dados pós-produção, como demanda e indicadores operacionais.

A Figura 1 traz a tela principal do sistema, a qual é dividida em cinco estágios, que correspondem as etapas clássicas da manufatura.




Figura 1: DeepFactory: Sistema dividido em estágios, de acordo com estágios da produção.

Cada estágio é composto por três componentes principais: (i) uma camada de visualização com métricas e informações relevantes, (ii) modelos descritivos, preditivos e/ou prescritivos — incluindo métodos de otimização e aprendizado de máquina — voltados aos desafios específicos daquele contexto, e (iii) um agente de IA, especialista naquele contexto, que é responsável por interpretar os resultados e gerar insights em linguagem natural para apoio à decisão. Além da geração de insights, os agentes também podem executar tarefas associadas aos problemas identificados, permitindo não apenas a análise, mas também a ação sobre o sistema produtivo.




Figura 2: Arquitetura do Sistema Multiagentes: Sistema de agentes integrado à visão geral, chat e às fontes de dados.

A Figura 2 ilustra a arquitetura geral de agentes de IA da solução. Cada agente especialista tem acesso completo ao contexto e aos dados do estágio de produção pelo qual ele é responsável, sendo capaz de realizar análises detalhadas dos dados por meio de ferramentas desenvolvidas especificamente para esse propósito, fornecendo informações relevantes ao ambiente. O código-fonte de implementação dos agentes com seus prompts completos está disponível em repositório online.¹

O conjunto de agentes do sistema pode ser acionado de duas formas. A primeira forma é reativa: os agentes são acionados sob demanda por meio de uma interface conversacional, na qual um agente gerenciador (*manager*) interpreta as solicitações do usuário e delega tarefas aos especialistas adequados. A segunda forma é proativa, na qual cada agente especialista analisa continuamente os dados do seu estágio e gera automaticamente insights que são apresentados no dashboard correspondente, permitindo ao usuário obter novas análises com um clique.

A forma como o usuário interage com o sistema, agentes e modelos é resumida na Tabela 1.

¹<https://github.com/Deeptera/DeepFactory-Sistema-Multi-Agentes>

Tabela 1: Fluxo detalhado de interação do usuário com o sistema

1. Planejamento de Materiais	Ações do Usuário: Cadastra produtos, insumos e níveis de estoque. Ações do Agente Coordenador de Insumos: - Aciona modelo SARIMAX para previsão de demanda. - Calcula cobertura de estoque. - Gera insights sobre a situação de abastecimento, identificando possíveis riscos de ruptura e recomendando ações como abertura de ordens de compra ou revisão de pedidos existentes.
2. Planejamento e Sequenciamento de Produção	Ações do Usuário: Cadastra o pedido de produção, definindo itens e quantidades. Ações do Agente Planner: - Aciona o solver GLPK com o modelo de programação inteira mista (MIP). - Apresenta os resultados otimizados. - Gera insights destacando a redução de gargalos e a melhoria na utilização das linhas de produção.
3. Execução de Produção	Ações do Usuário: Solicita análises e acompanha a execução do plano. Ações do Agente Executor: - Coleta dados das linhas de produção. - Aciona modelo de previsão de manutenção (Remaining Useful Life – RUL). - Gera insights sobre situações de risco e recomenda intervenções preventivas.
4. Controle de Qualidade	Ações do Usuário: Fornece gravações ou configurações de câmeras. Ações do Agente Sentinela: - Identifica objetos e danos em embalagens utilizando YOLO e ByteTrack. - Extrai e armazena métricas, incluindo número de detecções por SKU, classificação de defeitos e distribuição das ocorrências. - Gera insights sobre padrões de não conformidade e recomenda ajustes no processo produtivo.
5. Análise de Performance	Ações do Usuário: Solicita análises e insights gerais. Ações do Agente Analista: - Consolida dados dos estágios anteriores, gerando métricas globais de desempenho. - Apresenta insights estratégicos, como identificação de gargalos, inconsistências operacionais e oportunidades de melhoria.

Os parâmetros adotados nos modelos foram definidos para fins de demonstração do sistema integrado. As subseções seguintes descrevem os agentes e os seus modelos.

3.1. Agente Coordenador de Insumos: Planejamento de Materiais

Este agente atua no estágio de planejamento de materiais (MRP), gerenciando insumos, níveis de estoque e ordens de compra. Sua função principal é garantir o abastecimento da produção, fornecendo suporte direto às decisões de reposição. Para isso, o agente opera dois modelos analíticos:

Previsão de Demanda com SARIMAX. Além disso, o agente utiliza aprendizado de máquina para prever a demanda futura. O modelo SARIMAX é aplicado por SKU com parâmetros $(1, 1, 1) \times (1, 1, 1)_7$. A série passa por pré-processamento com detecção de *outliers* via *z-score* e transformação logarítmica para estabilização da variância. A avaliação por validação temporal com separação treino-teste apresentou MAE de 230,18, RMSE de 247,46 e MAPE de 14,3% para um SKU com média de produção de 1750 unidades/dia, indicando aderência satisfatória do modelo para suporte ao planejamento de curto prazo.

Modelo de Cobertura de Estoque. Consiste em um modelo determinístico que estima a autonomia do estoque atual com base no consumo histórico e na lista de materiais (BOM). Dado um insumo i e um horizonte de D dias, a cobertura é dada por $Cov_i(D) = \frac{E_i}{\bar{c}_i(D)}$, onde $\bar{c}_i(D) = \frac{1}{D} \sum_{j \in \mathcal{J}_D} b_{i,j} P_j(D)$, sendo $b_{i,j}$ o coeficiente de consumo e $P_j(D)$ a produção total do SKU j .

3.2. Agente Planner: Planejamento e Sequenciamento

O agente *Planner* é o especialista responsável pelas atividades de PCP/APS. Ele gerencia a fila de pedidos e busca a melhor alocação em linhas paralelas de produção, visando minimizar o *makespan* e os tempos de *setup*. Este agente aciona o modelo de otimização de sequenciamento - Programação Inteira Mista (MIP) - descrito a seguir.

Sejam N o conjunto de jobs e $\mathcal{M}$ o conjunto de linhas de produção. Para cada job $j \in N$, o tempo de processamento na linha $l \in \mathcal{M}$ é $p_{j,l} = d_j/v_{l,j}$, onde d_j é a demanda e $v_{l,j}$ a velocidade de produção. Os tempos de *setup* ao trocar do job i para j são dados por $s_{i,j}$, e $A_{l,j} \in \{0, 1\}$ indica se a linha l pode processar o job j .

As variáveis de decisão são: $x_{j,l} \in \{0, 1\}$ (alocação do job j à linha l), $z_{i,j,l} \in \{0, 1\}$ (precedência de i sobre j na linha l), $first_{j,l}, last_{j,l} \in \{0, 1\}$ (primeiro e último job na linha), $C_j \geq 0$ (tempo de conclusão) e $C_{\max} \geq 0$ (*makespan*). O modelo é então:

$$\min C_{\max} \quad (1)$$

$$\text{s.a.} \quad \sum_l x_{j,l} = 1 \quad \forall j \in N \quad (2)$$

$$first_{j,l} + \sum_{i \neq j} z_{i,j,l} = x_{j,l} \quad \forall j, l \quad (3)$$

$$last_{j,l} + \sum_{k \neq j} z_{j,k,l} = x_{j,l} \quad \forall j, l \quad (4)$$

$$\sum_j first_{j,l} \leq 1 \quad \forall l \quad (5)$$

$$z_{i,j,l} \leq x_{i,l}, \quad z_{i,j,l} \leq x_{j,l} \quad \forall i \neq j, \forall l \quad (6)$$

$$C_j \geq p_{j,l} \cdot first_{j,l} \quad \forall j, l \quad (7)$$

$$C_j \geq C_i + p_{j,l} + s_{i,j} - M(1 - z_{i,j,l}) \quad \forall i \neq j, \forall l \quad (8)$$

$$C_{\max} \geq C_j \quad \forall j \in N \quad (9)$$

$$x_{j,l} \leq A_{l,j} \quad \forall j, l \quad (10)$$

A função objetivo (1) consiste em minimizar o *makespan*, ou seja, o tempo total necessário para finalizar todos os jobs, buscando balancear a carga entre as linhas de produção e reduzir gargalos e ociosidade.

As restrições do modelo garantem a construção de uma solução viável de forma estruturada. A restrição (2) assegura que cada job seja alocado a exatamente uma linha de produção. As restrições (3) e (4) garantem a consistência da sequência em cada linha, impondo que cada job tenha no máximo um predecessor e um sucessor, ou seja, seja corretamente posicionado na sequência. A restrição (5) limita a existência de um único job inicial por linha.

A restrição (6) vincula as relações de precedência às alocações, garantindo que apenas jobs na mesma linha possam ter ordem definida entre si. As restrições (7) e (8) tratam da coerência temporal, definindo corretamente os tempos de conclusão dos jobs, considerando tanto o tempo de processamento quanto os tempos de *setup* entre tarefas consecutivas.

A restrição (9) define o *makespan* como o maior tempo de conclusão entre todos os jobs, enquanto a restrição (10) garante que cada job seja alocado apenas a linhas capazes de processá-lo.

O agente interpreta a solução do modelo, auxiliando o usuário na compreensão dos trade-offs envolvidos e sugerindo planos que reduzem o tempo ocioso e os gargalos operacionais.

3.3. Agente Executor: Gestão de Execução e Manutenção

O agente *Executor* monitora o ambiente de chão de fábrica em tempo real, atuando como a inteligência por trás do sistema MES. Ele acompanha a vida útil das linhas de produção, por meio do modelo que estima o tempo restante de vida de um equipamento (*Remaining Useful Life* - RUL), descrito a seguir.

O RUL (*Remaining Useful Life*) dos equipamentos é estimado utilizando um regressor de *gradient boosting*/XGBoost. As características levadas em conta pelo modelo incluem estatísticas de variáveis como tensão, rotação, pressão e vibração, além de indicadores de erro, idade operacional e identificação do equipamento.

O objetivo é aprender uma função $f : \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ tal que $\hat{y} = f(x)$, com predição operacional $\widehat{RUL} = \max(0, \hat{y})$. O risco crítico é definido por comparação com um limiar τ (no sistema, $\tau = 30$), sendo a linha sinalizada quando $\widehat{RUL} \leq \tau$.

As inferências são realizadas por linha de produção, a partir da telemetria mais recente. Seja x_ℓ o vetor de características da linha ℓ ; então:

$$\widehat{RUL}_\ell = \max(0, f(x_\ell)). \quad (11)$$

A flag de risco é definida por:

$$risco_crítico_\ell = \begin{cases} verdadeiro, & \text{se } \widehat{RUL}_\ell \leq \tau, \\ falso, & \text{caso contrário.} \end{cases} \quad (12)$$

Essa proatividade permite que o agente recomende intervenções preventivas, reduzindo paradas não planejadas.

3.4. Agente Sentinela: Controle de Qualidade

O agente *Sentinela* é focado na inspeção final do processo produtivo. Ele simula um ambiente de visão computacional para detecção de defeitos em embalagens utilizando fluxos de vídeo, por meio do pipeline analítico, que utiliza o modelo YOLO para classificação binária, precedido por filtros de *unsharp masking* e CLAHE. Para garantir a precisão da contagem, o agente utiliza o rastreamento *ByteTrack*, mantendo apenas a detecção de maior confiança por trajetória:

$$d^* = \arg \max_{d \in \mathcal{T}} \text{conf}(d) \quad (13)$$

O agente identifica padrões de não conformidade por SKU e gera alertas sobre concentração de defeitos, permitindo ajustes rápidos no processo produtivo.

3.5. Agente Analista: Performance e Inteligência Estratégica

O agente *Analista* atua na camada superior de inteligência, consolidando as informações geradas por todos os outros especialistas. Ele é responsável por interpretar o estado global da operação, incluindo pendências operacionais, como pedidos sem linha atribuída ou inconsistências cadastrais, e utiliza LLMs para traduzir dados complexos em recomendações estratégicas para a gestão industrial.

4. Caso de uso

Esta seção descreve um cenário de uso do DeepFactory a partir da perspectiva do usuário, detalhando o fluxo de interação com o sistema, incluindo entradas fornecidas, processamento realizado, saídas geradas e decisões tomadas. O objetivo é ilustrar o papel dos agentes de IA, dos modelos e o funcionamento do sistema multiagente na tomada de decisão ao longo do processo produtivo.

Os casos foram explorados com dados sintéticos, inspirados em cenários reais de manufatura, preservando características como sazonalidade semanal, variação de demanda e presença de ruído. Foram simulados dados de produção, tempos de setup, falhas de equipamentos e não conformidades de forma consistente com restrições operacionais realistas. O cenário considera um pedido composto por seis itens: Pomada anti-inflamatória (66 un.), Dipirona 500 mg (337), Dipirona gotas 500 mg/ml (93), Paracetamol 750 mg (106), Omeprazol 20 mg (475) e Loratadina 10 mg (214), distribuídos em duas linhas de produção. A sequência de cadastro define um plano base (baseline), utilizado para comparação com a solução otimizada.

4.1. Planejamento de Materiais

O fluxo de uso inicia-se com o acesso do usuário ao módulo de planejamento de materiais, no qual são disponibilizadas informações sobre níveis de estoque, histórico de consumo e requisições em aberto. A partir desses dados, o sistema executa automaticamente o cálculo de cobertura de estoque e o modelo de previsão de demanda baseado em SARIMAX, sem necessidade de intervenção manual inicial.

Como resultado, o sistema apresenta indicadores de cobertura em dias para cada insumo, bem como previsões de demanda para os próximos períodos. Com base nesses dados, o agente *Coordenador de Insumos* analisa a situação de abastecimento e identifica possíveis riscos de ruptura, gerando alertas e recomendações, como a necessidade de abertura de ordens de compra ou revisão de pedidos existentes.

Na Figura 3, o agente retorna a previsão de demanda da Amoxicilina, o que pode ser usado pelo usuário para planejar a produção dos próximos dias, sabendo também que seu estoque é suficiente para produzir, como afirmado pelo agente.




Figura 3: Estágio de planejamento de materiais

4.2. Planejamento e Sequenciamento da Produção

Na etapa seguinte, o usuário acessa o módulo de planejamento e sequenciamento, onde cadastra explicitamente o pedido de produção, definindo os itens a serem produzidos e suas respectivas quantidades. Após a inserção desses dados, o usuário solicita a execução do modelo de otimização.

O sistema então processa o problema de sequenciamento por meio do modelo de sequenciamento, considerando tempos de processamento dependentes das linhas e tempos de setup dependentes da sequência. Como saída, é gerado um plano otimizado contendo a alocação dos jobs às linhas de produção, a sequência de execução e os indicadores de desempenho associados.

A Tabela 2 apresenta a comparação entre o plano base, definido pela ordem de cadastro, e a solução otimizada. Observa-se uma redução de 33% no tempo de setup e um makespan de aproximadamente 3h47min, em contraste com $\approx 5h39min$ do plano original.

Tabela 2: Comparação entre plano base e solução otimizada

Método	Setup	Makespan	Observação
Plano base (ordem de cadastro)	3h25min	≈ 5h39min	Sequência original (ordenado)
MIP	2h17min	3h47min	Sequenciamento otimizado
Economia	↓ 33%	≈ 1h52min	—

O agente *Planner* interpreta os resultados gerados pelo modelo e apresenta ao usuário uma análise dos ganhos obtidos, destacando a redução de gargalos e a melhoria na utilização das linhas de produção. Com base nesses insights, o usuário valida o plano otimizado e o encaminha para execução.

4.3. Execução da Produção

Com o plano definido, o usuário inicia a execução da produção no sistema. Durante essa etapa, o DeepFactory passa a analisar dados de telemetria das linhas de produção em tempo real, incluindo variáveis operacionais relevantes.

Esses dados são processados pelo modelo de manutenção preditiva, que estima o Remaining Useful Life (RUL) dos equipamentos. Como saída, o sistema apresenta indicadores atualizados do estado das linhas e estimativas de vida útil.

Na Figura 4, o *Executor* identifica que uma das linhas de produção está com vida útil restante muito baixa, e que no momento nenhuma linha está sendo utilizada. Assim, com base nessas informações, o usuário pode determinar que esse é um bom momento para realizar a manutenção do equipamento.




Figura 4: Estágio de execução de produção

4.4. Controle de Qualidade

Na etapa de controle de qualidade, o usuário fornece ao sistema vídeos de inspeção das embalagens produzidas, associados aos respectivos SKUs. Esses dados são processados por algoritmos de visão computacional utilizando YOLO e rastreamento com ByteTrack, que detectam defeitos nas embalagens.

Como resultado, o sistema apresenta métricas agregadas de qualidade, incluindo número de detecções por SKU, classificação de defeitos e distribuição das ocorrências.

O agente *Sentinela* analisa esses resultados e identifica padrões de não conformidade, destacando possíveis problemas recorrentes no processo produtivo, como exibido na Figura 5, onde ele identifica que o número de amassados nas embalagens de Dipirona está muito alto, o que pode estar relacionado a um problema no processo de embalagem. Com base nessas informações, o usuário avaliará se existem erros no processo, visando garantir a qualidade dos produtos.




Figura 5: Estágio de controle de qualidade

4.5. Análise de Performance

Por fim, o usuário acessa o módulo de análise de performance, onde são consolidadas informações provenientes de todos os estágios anteriores. O sistema processa esses dados para gerar indicadores globais de desempenho, incluindo métricas de produção, qualidade e eficiência operacional.

Na Figura 6, o *Analista* indica que a demanda caiu em março, informação importante para que o usuário possa se planejar para a execução no próximo ano, como forma de evitar excedente de produção.

A partir dessa visão integrada, o usuário utiliza os resultados para retroalimentar o processo de planejamento, promovendo ajustes contínuos e melhoria do desempenho produtivo.




Figura 6: Estágio de análise de performance

De forma geral, o caso de uso buscou ilustrar um fluxo completo de interação com o sistema, no qual o usuário percorre todas as etapas do processo produtivo com suporte contínuo de modelos analíticos e agentes inteligentes, transformando dados operacionais em decisões acionáveis ao longo de todo o ciclo.

5. Conclusão

Este trabalho apresentou o DeepFactory, uma plataforma multiagente que integra, em uma única arquitetura orientada por estágios, planejamento de materiais, sequenciamento em múltiplas linhas, execução no chão de fábrica, controle de qualidade por visão computacional e análise de performance. A principal contribuição do trabalho reside na integração unificada de modelos de otimização, aprendizado de máquina e visão computacional em um sistema multiagente capaz de atuar de forma contínua ao longo de todo o processo produtivo, conectando decisões estratégicas, táticas e operacionais.

Os resultados obtidos evidenciam o potencial da abordagem. No estudo de caso, o modelo de otimização baseado em programação inteira mista (MIP) ilustra o potencial do sistema, reduzindo o tempo de *setup*, além de minimizar o *makespan*, o que se traduz em ganhos na eficiência produtiva. De forma complementar, o modelo de cobertura de estoque e a previsão de demanda apoiam decisões de abastecimento e antecipação de necessidades, enquanto o regressor de manutenção preditiva permite identificar riscos de falha e priorizar intervenções. No controle de qualidade, o pipeline de visão computacional viabiliza a detecção automatizada de defeitos, fornecendo métricas objetivas sobre a qualidade da produção.

Além dos modelos analíticos, o uso de agentes de IA mostrou-se relevante para a operacionalização do sistema, traduzindo dados e resultados em insights acionáveis em linguagem natural. Essa camada contribui para a interpretabilidade e facilita a adoção dos modelos em contextos reais de manufatura. O trabalho representa também uma oportunidade de compartilhamento de aplicações de modelos de inteligência artificial generativa na Indústria.

Como trabalhos futuros, destacam-se: (i) a validação do sistema em ambientes industriais reais, considerando variabilidade operacional, ruído nos dados e integração com sistemas legados; (ii) o refinamento, calibração e validação dos modelos com dados reais de produção; (iii) a extensão do modelo de sequenciamento para cenários dinâmicos, com replanejamento em tempo real e incertezas na demanda e na disponibilidade de recursos; e (iv) a incorporação de modelos de visão e linguagem (VLMs), visando ampliar a capacidade de interação do usuário com o módulo de controle de qualidade via linguagem natural.

6. Agradecimentos

O presente trabalho foi realizado com o apoio da Fundação de Amparo à Pesquisa do Estado de Minas Gerais (FAPEMIG), por meio do projeto processo nº APQ-06907-25 (Edital Compete Minas).

Referências

- Abidi, M. H., Mohammed, M. K., e Alkhalefah, H. (2022). Predictive maintenance planning for industry 4.0 using machine learning for sustainable manufacturing. *Sustainability*, 14(6):3387.
- Doanh, D. C., Dufek, Z., Ejdy, J., Ginevičius, R., Korzynski, P., Mazurek, G., Paliszkievicz, J., Wach, K., e Ziemba, E. (2023). Generative ai in the manufacturing process: theoretical considerations. *Engineering Management in Production and Services*, 15(4):76–89.
- Elkateb, S., Métwalli, A., Shendy, A., e Abu-Elanien, A. E. (2024). Machine learning and iot-based predictive maintenance approach for industrial applications. *Alexandria Engineering Journal*, 88: 298–309.
- Greis, N. P., Cherukuri, H. P., e Outeiro, J. C. (2025). Multi-agent systems for manufacturing digital twins: A perspective on agency and large language models. *IFAC-PapersOnLine*, 59(10): 1612–1617.
- Islam, M. R., Zamil, M. Z. H., Rayed, M. E., Kabir, M. M., Mridha, M. F., Nishimura, S., e Shin, J. (2024). Deep learning and computer vision techniques for enhanced quality control in manufacturing processes. *IEEE Access*, 12:121449–121479.
- Momenikorbekandi, A. e Kalganova, T. (2025). Intelligent scheduling methods for optimisation of job shop scheduling problems in the manufacturing sector: A systematic review. *Electronics*, 14 (8):1663.
- Moser, M., Musliu, N., Schaerf, A., e Winter, F. (2022). Exact and metaheuristic approaches for unrelated parallel machine scheduling. *Journal of Scheduling*, 25(5):507–534.

- Naderi, B., Ruiz, R., e Roshanaei, V. (2023). Mixed-integer programming vs. constraint programming for shop scheduling problems: new results and outlook. *INFORMS journal on computing*, 35(4):817–843.
- Neto, A., Almeida, C. S. J. d., Macedo, R. D., Duque, A. H., e Almeida, S. J. d. (2025). Proposta de um sistema multiagentes baseado em LLM: Integração em um software de gerenciamento e otimização de carregamento e descarregamento de navios. In *Anais do Simpósio Brasileiro de Automação Inteligente (SBAI)*. Sociedade Brasileira de Automática. Proceedings SBAI-SBSE 2025.
- Nie, Q., Tang, D., Zhu, H., e Sun, H. (2022). A multi-agent and internet of things framework of digital twin for optimized manufacturing control. *International Journal of Computer Integrated Manufacturing*, 35(10-11):1205–1226.
- Russell, S. e Norvig, P. (2010). *Artificial Intelligence: A Modern Approach*. Prentice Hall, 3 edition.
- Sistla, S. M. K., Krishnamoorthy, G., Jeyaraman, J., e Konidena, B. K. (2024). Machine learning for demand forecasting in manufacturing. *Int J Multidiscip Res (IJFMR)*, 6:1–11.
- Tsallis, C., Papageorgas, P., Piromalis, D., e Munteanu, R. A. (2025). Application-wise review of machine learning-based predictive maintenance: Trends, challenges, and future directions. *Applied Sciences*, 15(9):4898.
- Vyskočil, J., Douda, P., Novák, P., e Wally, B. (2023). A digital twin-based distributed manufacturing execution system for industry 4.0 with ai-powered on-the-fly replanning capabilities. *Sustainability*, 15(7):6251.
- Wooldridge, M. (2009). *An introduction to multiagent systems*. John wiley & sons.
- Yang, H., Kumara, S., Bukkapatnam, S. T., e Tsung, F. (2019). The internet of things for smart manufacturing: A review. *IIE Transactions*, 51(11):1190–1216.
- Zhong, R. Y., Xu, X., Klotz, E., e Newman, S. T. (2017). Intelligent manufacturing in the context of industry 4.0: A review. *Engineering*, 3(5):616–630. ISSN 2095-8099.
- Zhou, L., Zhang, L., e Konz, N. (2022). Computer vision techniques in manufacturing. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 53(1):105–117.