



ROTEAMENTO MULTI-PERÍODO DE DRONES COM JANELAS DE TEMPO E DISPONIBILIZAÇÃO GRADUAL DE ESTAÇÕES DE RECARGA

Antonio S. C. Neto - antonio.couto@sga.pucminas.br
Pontifícia Universidade Católica de Minas Gerais - PUCMG

Zenilton K. G. do Patrocínio - zenilton@sga.pucminas.br
Pontifícia Universidade Católica de Minas Gerais - PUCMG

ÁREA: 03. PESQUISA OPERACIONAL

SUBÁREA: 3.1 - Modelagem, Simulação e Otimização

RESUMO: Este artigo propõe uma extensão multi-período do Problema de Roteamento de Veículos Elétricos com Janelas de Tempo aplicada a entregas por drones com disponibilização gradual de estações de recarga. A demanda e a infraestrutura evoluem ao longo dos períodos, e as soluções são avaliadas considerando distância, atraso e inviabilidade energética. Para resolver o problema, é proposta a MP-EAVNS, uma metaheurística baseada em Busca em Vizinhança Variável com mecanismos de reparo energético e herança entre períodos. O método foi avaliado em 9.936 execuções sobre instâncias do benchmark E-VRPTW. Os resultados mostram que a abordagem atinge 100% de viabilidade sob disponibilidade completa e 98,6% sob disponibilização gradual, além de produzir rotas até 6,7% mais curtas que métodos de referência. Conclui-se que a disponibilização gradual preserva grande parte do desempenho da infraestrutura completa.

PALAVRAS-CHAVES: Roteamento de Veículos Elétricos; Drones; Metaheurísticas; Busca em Vizinhança Variável; Otimização; Logística

1. INTRODUÇÃO

Problemas de roteamento formam uma das bases da otimização combinatória aplicada à logística. O Problema de Roteamento de Veículos (Vehicle Routing Problem – VRP) (Dantzig and Ramser 1959) generaliza a decisão de construir rotas para uma frota, enquanto o VRP com Janelas de Tempo (VRP with Time Windows – VRPTW) (Solomon 1987) incorpora compromissos entre custo espacial e nível de serviço. Outras extensões, como o Problema de Coleta e Entrega (Pickup and Delivery Problem – PDP) (Savelsbergh and Sol 1995; Li and Lim 2001) e o roteamento dinâmico (Psaraftis 1988; Berbeglia et al. 2010; Pillac et al. 2013), mostram que restrições temporais, decisões sequenciais e operadores de reparo são componentes recorrentes em problemas logísticos reais.

A eletrificação da frota acrescenta uma restrição adicional: a rota só é operacionalmente viável se respeitar a autonomia do veículo e a disponibilidade de recarga. O Problema de Roteamento de Veículos Elétricos com Janelas de Tempo (Electric Vehicle Routing Problem with Time Windows – E-VRPTW) (Schneider et al. 2014) tornou-se referência para esse cenário ao combinar janelas de tempo, bateria limitada e estações intermediárias; seu conjunto de instâncias (Goeke 2019) deriva das instâncias de Solomon e é amplamente usado para comparação experimental. Revisões recentes de roteamento verde e veículos elétricos reforçam que infraestrutura de recarga, autonomia e escolha de estações não são apenas detalhes operacionais, mas decisões que afetam diretamente a estrutura das rotas (Asghari and Mirzapour Al-e-hashem 2021; Ghorbani et al. 2020; Stamadianos et al. 2023).

Em drones de entrega, essa dependência é ainda mais forte. A autonomia é menor, a capacidade de carga é reduzida e a margem energética tende a ser mais apertada do que em veículos terrestres. Revisões sobre sistemas de entrega por drones destacam autonomia, recarga e pontos de apoio como fatores centrais de planejamento (Raivi et al. 2023). Trabalhos recentes já estudam veículos aéreos não tripulados (Unmanned Aerial Vehicles – UAVs) com janelas de tempo e recarga (Shi et al. 2023), formulações multiobjetivo para roteamento verde de UAVs (Coelho et al. 2017), problemas de localização-roteamento com estações em aplicações industriais (Ribeiro et al. 2020) e roteamento de drones com localização de estações em armazéns (Vichitkunakorn et al. 2024).

Apesar desses avanços, a maior parte da literatura considera um único horizonte de decisão e assume que a infraestrutura de recarga está fixa e disponível desde o início. Essa hipótese é forte para operações em expansão: uma rede de entregas por drones tende a crescer gradualmente, tanto pela entrada de novos clientes quanto pela disponibilização progressiva

de estações externas. Nesse contexto, uma decisão relevante não é apenas qual rota construir com a infraestrutura completa, mas quanto desempenho pode ser preservado antes que toda a infraestrutura esteja disponível.

Este artigo investiga essa questão por meio do Problema de Roteamento Multi-período de Drones com Estações de Recarga (PRMD-ER), uma extensão do E-VRPTW reinterpretada para drones. Em cada período, há um conjunto de clientes ativos C_t e um conjunto de estações externas disponíveis F_t ; ambos crescem ao longo do horizonte. Três políticas de estações são comparadas: apenas depósito, disponibilidade gradual e disponibilidade completa. As janelas de tempo e a bateria são tratadas como restrições flexíveis, com penalidades explícitas para atraso e inviabilidade energética.

Para resolver o problema, é proposta a MP-EAVNS (Multi-Period Energy-Aware Variable Neighborhood Search), uma Busca em Vizinhança Variável sensível à energia. O método combina construção randomizada, cinco vizinhanças de clientes, reparo energético por visitas a estações existentes e inicialização herdada entre períodos. A escolha por buscas em vizinhança é coerente com a literatura de roteamento com múltiplas restrições, na qual operadores de vizinhança, destruição-reconstrução e reparo são amplamente usados para lidar com soluções parcialmente inviáveis (Ropke and Pisinger 2006; Mladenović and Hansen 1997; Cai et al. 2022; Zhou et al. 2024).

A contribuição do trabalho é tripla: formalizar um cenário multi-período de entregas por drones com disponibilização gradual de estações, avaliar seu impacto sobre a viabilidade energética e comparar a MP-EAVNS com heurísticas construtivas e metaheurísticas de referência. Os resultados separam objetivo penalizado, viabilidade energética e distância em soluções viáveis, de modo que o efeito da infraestrutura possa ser analisado.

O restante do artigo está organizado como segue. A seção de trabalhos relacionados posiciona o PRMD-ER na literatura; a seção de metodologia formaliza o problema e detalha a MP-EAVNS; a seção de resultados apresenta os experimentos; e a seção de conclusão resume os achados e limitações.

2. TRABALHOS RELACIONADOS

O VRPTW (Solomon 1987) é a base clássica para rotas com compromisso entre distância e atendimento dentro de janelas de tempo. O E-VRPTW adotado neste trabalho preserva essa estrutura e acrescenta autonomia limitada e estações de recarga. O PRMD-ER parte dessa base e introduz uma dimensão multi-período, na qual os conjuntos de clientes

ativos C_t e de estações disponíveis F_t crescem ao longo do horizonte. Assim, mantém-se a estrutura clássica de atendimento com janelas de tempo, mas a principal dificuldade passa a ser a interação entre crescimento da demanda e disponibilidade energética.

Sob informação parcial e restrições acopladas, métodos exatos perdem tração rapidamente, o que levou a literatura de roteamento a consolidar metaheurísticas baseadas em vizinhanças e reparo. A ALNS (Adaptive Large Neighborhood Search) (Ropke and Pisinger 2006) adapta a escolha de operadores de destruição e reconstrução conforme o desempenho histórico, enquanto a VNS (Mladenović and Hansen 1997) alterna vizinhanças distintas para escapar de ótimos locais.

A literatura recente de Problemas Dinâmicos de Coleta e Entrega (Dynamic Pickup and Delivery Problem, DPDP), sintetizada na revisão de (Cai et al. 2023), reforça que decisões sequenciais, informação parcial e múltiplas restrições operacionais exigem métodos capazes de corrigir soluções incompletas ou degradadas ao longo da busca. Nesse contexto, aplicações recentes ao DPDP — como VNS para variantes práticas (Cai et al. 2022) e algoritmos meméticos que combinam busca populacional com refinamento local (Zhou et al. 2024) — indicam que alternar vizinhanças estruturais e aplicar operadores de reparo são mecanismos recorrentes em soluções competitivas. O PRMD-ER adota essa linha, mas desloca o foco para viabilidade energética e disponibilização gradual de infraestrutura.

A viabilidade energética, antes ausente do VRP clássico, foi gradualmente incorporada pela literatura de roteamento verde. Revisões do Green VRP (Asghari and Mirzapour Al-e-hashem 2021) e classificações de variantes ambientalmente amigáveis (Ghorbani et al. 2020) cobrem veículos elétricos, recarga e troca de baterias; análises de problemas com veículos elétricos e autônomos (Stamadianos et al. 2023) destacam recarga e infraestrutura como decisões de primeira classe.

Dentro dessa linha, o E-VRPTW (Schneider et al. 2014) estabeleceu a referência para roteamento elétrico com janelas de tempo: veículos com bateria limitada atendem clientes e podem visitar estações intermediárias para recarga. O conjunto de instâncias associado (Goeke 2019) deriva das instâncias de Solomon e inclui clientes, depósito, estações e parâmetros energéticos. O PRMD-ER usa essa base e acrescenta três elementos: períodos com clientes ativos crescentes C_t , políticas de disponibilidade de estações F_t e uma avaliação penalizada que separa objetivo, viabilidade energética e distância em soluções viáveis.

Em drones, a margem energética é tipicamente menor do que em veículos elétricos terrestres, o que faz com que problemas reais raramente sejam apenas geométricos. Revisões

de sistemas de entrega por drones (Raivi et al. 2023) organizam a literatura em planejamento de trajetória, recarga e segurança, evidenciando que autonomia, recarga e disponibilidade de pontos de apoio afetam diretamente o roteamento.

Sobre esse pano de fundo, diversos trabalhos atacaram o roteamento de UAVs com recarga em variantes específicas. Há estudos com janelas de tempo e recarga resolvidos por busca adaptativa em grandes vizinhanças, com instâncias derivadas de Solomon na ausência de benchmarks padronizados (Shi et al. 2023); formulações multiobjetivo com autonomia limitada e múltiplas estações (Coelho et al. 2017); localização-roteamento de UAVs com estações para inspeção de correias transportadoras na mineração (Ribeiro et al. 2020), ilustrando a relevância industrial do tema; e combinações de localização de estações com roteamento de drones para inventário em armazéns (Vichitkunakorn et al. 2024).

Esses trabalhos confirmam a relevância da combinação UAV + recarga + localização, mas todos assumem horizonte único e infraestrutura fixa. A possibilidade de que ela evolua ao longo do tempo, exigindo decisões de roteamento sob essa evolução, é a lacuna que este trabalho aborda.

3. METODOLOGIA

Esta seção apresenta a formulação do PRMD-ER, as instâncias utilizadas, os algoritmos comparados e o método principal MP-EAVNS. São descritos a entrada de clientes, a disponibilidade de estações, a construção de rotas, o reparo energético e a herança entre períodos.

3.1 Formulação do Problema

Seja $G = (V, A)$ um grafo completo euclidiano com vértices $V = \{0\} \cup C \cup F$: depósito 0, clientes C e estações candidatas F . O depósito é único por instância, em conformidade com o *benchmark* E-VRPTW (Schneider et al. 2014; Goeke 2019). Cada cliente i tem demanda q_i , tempo de serviço s_i e janela $[a_i, b_i]$. Cada arco (i, j) tem distância euclidiana d_{ij} e tempo de viagem d_{ij}/v , com v a velocidade constante do drone. A frota é homogênea, com capacidade Q e bateria B medida em unidades de distância: o drone parte do depósito ou de uma estação com B unidades e cada arco consome d_{ij} . O modelo energético depende apenas da distância — não de carga, vento, altitude ou fases de pouso/decolagem — escolha consistente com o *benchmark* E-VRPTW e discutida como limitação na Seção 5.

O horizonte é dividido em períodos $T = \{1, \dots, H\}$. Em cada período t , apenas um subconjunto $C_t \subseteq C$ de clientes está ativo e apenas um subconjunto $F_t \subseteq F$ de estações externas está disponível. Os dois conjuntos só crescem ao longo dos períodos: $C_t \subseteq C_{t+1}$ e $F_t \subseteq F_{t+1}$. O conjunto C_t é determinado por ordenação angular crescente em torno do depósito, a partir

do eixo horizontal positivo, simulando uma expansão por setores da área atendida; sua cardinalidade é $|C_t| = \lceil |C| \cdot t/H \rceil$. O depósito permanece disponível como ponto de recarga em todos os cenários; as políticas abaixo controlam apenas a disponibilidade das estações externas:

- Depósito: $F_t = \emptyset$ em todo período, isto é, não há estações externas disponíveis e a recarga intermediária só pode ocorrer no próprio depósito;
- Gradual: as estações externas são disponibilizadas em H parcelas, sendo $|F_t| = \lceil |F| \cdot t/H \rceil$ a cardinalidade do conjunto externo disponível no período t . As estações concretas escolhidas para entrar em $F_t \setminus F_{t-1}$ são selecionadas por uma regra gulosa que minimiza, a cada estação adicionada, a soma das distâncias dos clientes em C_t à estação disponível mais próxima — isto é, cada nova estação é disponibilizada onde mais aproxima a infraestrutura dos clientes já atendidos no período. Esse acoplamento entre crescimento de demanda e expansão de infraestrutura é uma característica do PRMD-ER que não aparece em variantes E-VRPTW puras;
- Completa: $F_t = F$ em todo período, ou seja, toda a infraestrutura está disponível desde $t = 1$.

Uma solução do período t é um conjunto de rotas $x_t = \{R_1, \dots, R_m\}$, em que $m = R(x_t)$, que começam e terminam no depósito, atendem cada cliente em C_t exatamente uma vez, podem conter paradas intermediárias no depósito ou em estações de F_t , e respeitam

a capacidade de carga: para cada rota R , $\sum_{i \in R \cap C} q_i \leq Q$. Não há limite superior fixo de frota; novas rotas podem ser abertas, mas são penalizadas por $R(x_t)$ na função objetivo. Denotando por $D(x_t)$ a distância total, $A(x_t)$ o atraso total, $R(x_t)$ o número de rotas e $I(x_t)$ o número de trechos energeticamente inviáveis remanescentes após o reparo, a função objetivo penalizada do período t é:

$$\min F(x_t) = D(x_t) + \alpha A(x_t) + \gamma R(x_t) + \beta I(x_t)$$

com pesos fixados em $\alpha = 10$, $\gamma = 100$ e $\beta = 10^6$. Os valores de α e γ são compatíveis com as magnitudes de distância e número de rotas nas instâncias avaliadas. Já β é deliberadamente dominante: uma solução com trecho energeticamente inviável não deve dominar soluções viáveis apenas por ter menor distância ou menor atraso.

A função penalizada é usada como escalar único para aceitação de movimentos durante a busca, enquanto a análise final separa seus componentes em objetivo, viabilidade e distância viável. Autonomia, janelas de tempo e número de rotas são, portanto, tratados na função objetivo como termos ponderados, enquanto a capacidade de carga é mantida como restrição rígida. Essa escolha separa dois casos: inviabilidade algorítmica, quando a busca não encontra uma combinação viável apesar da infraestrutura disponível, e inviabilidade estrutural, quando as estações de F_t não bastam para conectar a rota. Como o reparo considera no máximo uma parada intermediária entre dois vértices consecutivos, arcos que exigiriam duas ou mais recargas são classificados como inviáveis. Nos experimentos, esse limite não

impede viabilidade sob a política Completa com $B \geq 80$, em que a MP-EAVNS atinge $I(x_t) = 0$ em todas as execuções.

Formalmente, o atraso de uma rota é:

$$A(R) = \sum_{i \in R \cap C} \max(0, \tau_i(R) - b_i)$$

em que $\tau_i(R)$ é o instante de início do serviço em i ao longo de R ; se a chegada ocorre antes de a_i , o drone espera até o início da janela. Denotando por $e(R, i)$ o nível de bateria disponível em i na rota R e por i^- o vértice anterior a i na mesma rota, a atualização de bateria é:

$$e(R, i) = e(R, i^-) - d_{i^-i} \quad e(R, i^-) = B \text{ se } i^- \in \{0\} \cup F_t$$


Na segunda linha, $e(R, i^-) = B$ representa a recarga antes da saída de i^- quando o vértice anterior é o depósito ou uma estação ativa. O arco é energeticamente viável quando $e(R, i) \geq 0$; valores negativos são permitidos na avaliação e penalizados por $I(x_t)$. A contagem de trechos inviáveis após o reparo é:

$$I(x_t) = \sum_{R \in x_t} |\{(i, j) \in R : e(R, j) < 0\}|$$

em que $(i, j) \in R$ denota um par de vértices consecutivos na sequência da rota.

A Figura 1 ilustra um período do PRMD-ER: o drone parte do depósito 0, visita clientes ativos e usa a estação f como parada intermediária antes de retornar.

FIGURA 1 – Um período do PRMD-ER.



Fonte: Elaborado pelo autor (2026).

3.2 Reparo Energético

Como a sequência de paradas em estações é determinada por uma decisão geométrica local — e não como parte da combinatória de clientes — adota-se um módulo de reparo independente, compartilhado por todos os algoritmos comparados. Ele percorre cada rota da esquerda para a direita simulando $e(R, \cdot)$ conforme a Equação [eq:autonomia]. Sempre que um arco (i, j) violaria $e(R, j) \geq 0$, o módulo procura uma estação já ativa $f \in F_t$ como parada

intermediária, sob dois critérios cumulativos:

1. Viabilidade: $e(R, i) \geq d_{if}$ e $B \geq d_{fj}$;
2. Custo mínimo: dentre as f viáveis, escolhe-se a que minimiza $\Delta_{ij}(f) = d_{if} + d_{fj} - d_{ij}$.

Se nenhuma estação satisfaz ambos, o arco permanece inviável e contribui com uma unidade em $I(x_t)$. O trajeto passa por $i \rightarrow f \rightarrow j$, sem retorno a i , e F permanece fixo: o reparo apenas escolhe qual estação já instalada visitar. Essa separação entre roteamento e reparo torna os algoritmos comparáveis, já que todos produzem apenas a sequência de clientes e compartilham o módulo. O reparo é guloso por arco — minimiza o aumento local sem otimizar conjuntamente todas as paradas da rota.

3.3 Instâncias e Cenários

As 92 instâncias do *benchmark* E-VRPTW (Schneider et al. 2014; Goeke 2019) fornecem depósito, clientes, estações, demandas, janelas e tempos de serviço, com distâncias euclidianas. Cada instância é expandida em $H = 4$ períodos, com clientes ativados pela ordenação angular da Seção 3.1. As 36 instâncias pequenas têm 5, 10 ou 15 clientes; as 56 grandes têm 100. Os experimentos principais fixam $B = 80$; a sensibilidade varia $B \in \{60, 80, 100\}$.

3.4 Algoritmos Comparados

A comparação inclui nove algoritmos listados a seguir. Todos produzem apenas a sequência de clientes; as paradas de recarga são reconstruídas pelo módulo da Seção 3.2.

- EDD (*Earliest Due Date*): ordena clientes pelo fim da janela b_i ;
- Sweep: ordena clientes pelo ângulo polar em relação ao depósito;
- Nearest: construção gulosa que escolhe o cliente ainda não atendido mais próximo do último vértice da rota;
- GRASP (*Greedy Randomized Adaptive Search Procedure*): construção gulosa randomizada por lista restrita seguida de 2-opt, que inverte trechos de uma rota;
- ALNS: inicializada pela melhor entre Nearest, EDD e Sweep após esse refinamento 2-opt; usa três operadores de destruição (remoção aleatória, do pior e por relação espacial), dois de reparo (guloso e *regret-2*), aceitação por *simulated annealing* (Kirkpatrick et al. 1983) e pesos atualizados pelo esquema σ de (Ropke and Pisinger 2006);
- MP-EAVNS: método principal, descrito a seguir;
- Variantes da MP-EAVNS, cada uma com um componente desativado: sem herança (reinicializa cada período com a heurística Nearest), sem perturbação (encerra ao estagnar) e sem 2-opt auxiliar (omite chamadas extras de 2-opt; o reparo na avaliação permanece ativo).

3.5 MP-EAVNS


A MP-EAVNS estende a VNS clássica (Mladenović and Hansen 1997) para o ambiente multi-período com reparo energético. Parte da melhor solução entre EDD, Sweep, Nearest e múltiplas execuções da construção randomizada do GRASP, e explora cinco

vizinhanças encadeadas, aceitando apenas movimentos que reduzem F :

1. N_1 – 2-opt intra-rota: inverte um trecho de uma rota para reduzir distância;
2. N_2 – realocação: remove um cliente e o reinsere na melhor posição (intra- ou inter-rota);
3. N_3 – troca: troca dois clientes entre posições (intra- ou inter-rota);
4. N_4 – divisão: separa em duas uma rota cuja distância acumulada excede a autonomia;
5. N_5 – união: combina duas rotas curtas quando há folga de bateria e capacidade;
6. R_E – reparo energético: durante a avaliação, contabiliza uma parada em uma estação já ativa $f \in F_t$ sempre que o arco (i, j) violar a autonomia, escolhendo a parada que produz o menor aumento de distância $d_{if} + d_{fj} - d_{ij}$.

A Figura 2 ilustra cada movimento (linha superior: antes; linha inferior: depois). Quadrados denotam o depósito, círculos clientes, triângulos estações; arestas em laranja marcam arcos modificados.


FIGURA 2 – Efeito das cinco vizinhanças de clientes e do reparo energético sobre uma rota pequena.



Fonte: Elaborado pelo autor (2026).

Quando nenhuma vizinhança melhora a solução corrente, uma perturbação remove e reinsere uma fração dos clientes e a busca continua a partir da melhor solução conhecida. O processo executa até $k_{max} = 80$ iterações principais; uma perturbação é forçada quando a busca local estagna por quatro iterações consecutivas. A Figura 3 resume esse fluxo.

FIGURA 3 – Fluxo iterativo da MP-EAVNS.



Fonte: Elaborado pelo autor (2026).

A lógica multi-período altera apenas o ponto de partida da busca. Dada a melhor solução x_t^* do período t , o período $t + 1$ começa por copiar essa solução; as rotas copiadas, porém, não ficam fixas e podem ser modificadas pela busca local subsequente. Cada novo cliente em $C_{t+1} \setminus C_t$ é inserido na posição de menor aumento marginal de distância, abrindo uma nova rota quando necessário.

Depois dessa inserção, o reparo energético é reexecutado com as estações disponíveis em F_{t+1} . Assim, a herança preserva estrutura útil entre períodos consecutivos, mas a viabilidade final continua dependendo do reparo e da busca local no período corrente.

4. RESULTADOS

Os experimentos cobrem as 92 instâncias do *benchmark* E-VRPTW reinterpretado, com quatro períodos, três políticas e nove algoritmos — $92 \times 4 \times 3 \times 9 = 9.936$ execuções, com $B = 80$ fixo. Hardware: Intel Core i7-13650HX (16 GB de RAM), Windows 11, Python 3.12.10, uma única *thread* por execução.

4.1 Comparação entre algoritmos

A Tabela 1 apresenta as métricas médias agregadas sobre as três políticas. Como $\beta = 10^6$ na Equação [eq:objetivo], o objetivo penalizado é dominado por trechos inviáveis; por isso a análise também reporta a taxa de viabilidade ($I(x_t) = 0$) e, nas tabelas seguintes, distância restrita a soluções viáveis, que isolam o desempenho de roteamento puro.


TABELA 1 – Métricas médias por algoritmo ($B = 80$).

Algoritmo	Objetivo	Distância	Atraso	Rotas	Inviáveis
EDD	8.110.288	1.779,5	179,5	16,42	8,11
Sweep	4.293.766	1.303,2	1.180,3	16,74	4,28
Nearest	3.657.117	1.270,6	1.490,9	14,45	3,64
GRASP	2.525.490	1.368,2	908,8	14,46	2,51
ALNS	1.491.736	1.150,6	2,3	14,32	1,49
MP-EAVNS	1.617.556	1.071,0	1,7	14,31	1,62
MP-EAVNS sem 2-opt	1.630.227	1.071,9	0,5	14,32	1,63
MP-EAVNS sem perturb.	1.632.965	1.076,4	1,6	14,38	1,63
MP-EAVNS sem herança	1.936.032	1.174,6	45,8	14,29	1,93

Fonte: Elaborado pelo autor (2026).

No objetivo penalizado, a MP-EAVNS reduz a média em 36,0% frente ao GRASP e 56–80% frente às construtivas, ficando 8,4% acima da ALNS; esta, por sua vez, reduz o objetivo em 40,9% frente ao GRASP. A leitura agregada é afetada pela política Depósito (limite inferior sem estações externas e muitas inviabilidades estruturais); por isso, a Figura 4 separa viabilidade por política e compara distância nos regimes com infraestrutura externa, onde ALNS e MP-EAVNS empatam em viabilidade e a MP-EAVNS produz rotas viáveis mais curtas.

FIGURA 4 – Viabilidade por política (a) e distância média entre soluções viáveis nas políticas Gradual e Completa (b), considerando GRASP, ALNS e MP-EAVNS.



Fonte: Elaborado pelo autor (2026).

Quando a agregação é restrita às políticas com infraestrutura externa (Gradual e Completa), o ranking se inverte: a MP-EAVNS apresenta objetivo penalizado 0,7 % menor que a ALNS (9.306 contra 9.374). Assim, a vantagem agregada da ALNS na Tabela 1 deve ser lida como efeito do regime Depósito, não como superioridade geral de roteamento nos cenários operacionais de interesse.

4.2 Efeito da Política de Estações

A Tabela 2 compara as três políticas agregando todos os algoritmos (Recargas é o número médio de visitas a estações, distinto do $R(x)$ penalizado). A Completa funciona como limite superior; a Gradual fica apenas 2,3 % acima dela no objetivo e 89,5 % abaixo da política Depósito, recuperando quase todo o benefício energético. Distâncias médias de Gradual e Completa são praticamente iguais (1.253,9 vs. 1.252,3, +0,1 %); a degradação da Gradual aparece mais no atraso (431,9 vs. 427,0, +1,1 %) e na pequena inviabilidade residual.

TABELA 2 – Métricas médias por política de estações. Cada linha agrega 3.312 execuções (9 algoritmos $\times$ 92 instâncias $\times$ 4 períodos).

Política	Objetivo	Distância	Atraso	Recargas	Inviáveis
Depósito	7.423.220	1.249,2	411,6	1,07	7,42
Gradual	779.701	1.253,9	431,9	7,73	0,77
Completa	762.138	1.252,3	427,0	7,76	0,76

Fonte: Elaborado pelo autor (2026).

A média agregada esconde a interação algoritmo-política. A Tabela 3 reporta, por célula, a taxa de viabilidade e os trechos inviáveis médios. Sob Completa, MP-EAVNS e ALNS atingem 100 % de viabilidade (todas as 368 execuções); as construtivas ficam abaixo de 52 %. Sob Gradual, ambas as metaheurísticas mantêm-se acima de 98 % com apenas 0,01 trecho inviável médio — a coincidência corresponde às mesmas cinco combinações instância-período, casos estruturalmente apertados para o orçamento de busca adotado. As inviabilidades das construtivas sob Completa são predominantemente algorítmicas: a infraestrutura está toda disponível, mas sequências mal estruturadas produzem arcos que o reparo guloso não corrige.

TABELA 3 – Viabilidade e trechos inviáveis médios por algoritmo e política. Cada célula agrega 368 execuções.

Algoritmo	Depósito		Gradual		Completa	
	Viab.	Inv.	Viab.	Inv.	Viab.	Inv.
EDD	7,9	16,42	27,7	3,95	28,5	3,94
Sweep	9,2	9,55	50,3	1,65	51,9	1,63
Nearest	7,9	8,69	49,7	1,13	51,6	1,10
GRASP	14,4	7,33	89,1	0,12	92,1	0,08
ALNS	17,9	4,45	98,6	0,01	100,0	0,00
MP-EAVNS	17,9	4,83	98,6	0,01	100,0	0,00

Fonte: Elaborado pelo autor (2026).

Restringindo a comparação a soluções com $I(x_t) = 0$ (Tabela 4), neutraliza-se o termo β e isola-se o desempenho de roteamento puro: a MP-EAVNS produz rotas 6,7 % mais curtas que a ALNS sob Completa (1.072 vs. 1.149 unidades) e 6,2 % sob Gradual.

TABELA 4 – Distância média entre soluções viáveis, por algoritmo e política.

Algoritmo	Depósito	Gradual	Completa
EDD	137,0	370,1	366,0
Sweep	165,0	975,3	953,6
Nearest	145,7	725,9	707,6
GRASP	191,4	1.238,6	1.185,9
ALNS	188,9	1.158,9	1.148,9
MP-EAVNS	188,4	1.087,5	1.072,0

Fonte: Elaborado pelo autor (2026).

A distância sob Depósito (coluna 1) é menor apenas porque contém os casos geometricamente fáceis (clientes próximos ao depósito); a comparação relevante de distância está entre Gradual e Completa, que cobrem subconjuntos comparáveis de execuções viáveis. O cenário Depósito é dominado por inviabilidade estrutural — clientes além de $B/2$ não podem ser atendidos sem estações intermediárias — enquanto em Gradual e Completa a inviabilidade desaparece para as metaheurísticas, e a métrica relevante passa a ser a distância em soluções viáveis.

4.3 MP-EAVNS versus ALNS

A ALNS adaptada (Seção 3.4) é a referência natural para janelas de tempo. Ambos os métodos partem da melhor entre Nearest, EDD e Sweep com 2-opt; a MP-EAVNS adiciona construções randomizadas do GRASP ao pool de sementes. Como a MP-EAVNS reduz o objetivo médio em 36,0 % frente ao próprio GRASP (Tabela 1), o laço VNS concentra a maior parte do ganho e o GRASP atua como diversificação inicial. A comparação usa a mesma contagem de iterações ($K = 80$), embora a ALNS custe 14,44 s contra 3,73 s da MP-EAVNS — ou seja, sob orçamento de iterações, não de CPU. Três aspectos:

- Viabilidade. Empate: 100 % sob Completa e 98,6 % sob Gradual (Tabela 3).
- Objetivo agregado. A ALNS apresenta objetivo 7,8 % menor (MP-EAVNS 8,4 % acima), diferença que vem do regime Depósito — ALNS tem 4,45 trechos inviáveis

médios contra 4,83 da MP-EAVNS, possivelmente pela maior diversidade de seus operadores de destruição.

- Distância em soluções viáveis. Restringindo a $I(x_t) = 0$, a MP-EAVNS é 6,7% melhor que a ALNS sob Completa (1.072 vs. 1.149) e 6,2% melhor sob Gradual (Tabela 4) — o regime operacional de interesse.

A Tabela 5 resume a comparação pareada sob Completa, em execuções viáveis. A vantagem média da MP-EAVNS é de 76,9 unidades de distância (IC 95%: [65, 4, 88, 4]). O ganho não é uniforme: nas instâncias pequenas há empate técnico; nas grandes, a MP-EAVNS vence em 88,8% dos pares.

TABELA 5 – Comparação pareada MP-EAVNS versus ALNS em soluções viáveis sob Completa.

Classe	Casos	Vitórias MP	Empates	Dif. média
Pequenas	144	17,4 %	73,6 %	1,5
Grandes	224	88,8 %	0,0 %	125,4
Total	368	60,9 %	28,8 %	76,9

Fonte: Elaborado pelo autor (2026).

O alto número de empates nas pequenas é esperado: com poucos clientes, ambos os métodos atingem soluções de mesma distância. A ALNS vence em 10,3% dos pares totais (9,0% pequenas, 11,2% grandes), mostrando que a vantagem da MP-EAVNS não é universal — a diferença principal aparece nas grandes, onde a herança oferece um ponto de partida mais informativo.

4.4 Variantes Reduzidas da MP-EAVNS

As três variantes definidas na Seção 3.4 isolam o papel do 2-opt auxiliar, da perturbação e da herança entre períodos:

- Remover o 2-opt auxiliar tem efeito pequeno (+0,7% no objetivo, nulo na viabilidade), porque o reparo energético continua ativo na avaliação e N_1 cobre a maior parte das melhorias de 2-opt. O atraso médio menor (0,5 contra 1,7) é residual e reflete apenas uma troca local entre distância, rotas e atraso.
- Remover a perturbação custa +0,9% no objetivo, sugerindo que ela contribui pouco quando $N_1 - N_5$ já encontrou todas as melhorias acessíveis.
- Remover a herança entre períodos é o componente mais crítico: o objetivo médio cresce 19,7%, a distância de 1.071 para 1.175 e o atraso de 1,7 para 45,8. A inicialização herdada carrega a maior fração do ganho, sobretudo nos períodos finais.

4.5 Sensibilidade à Bateria

Sob a política Gradual, aumentar a autonomia reduz rapidamente a inviabilidade: a MP-EAVNS passa de 0,22 trechos inviáveis médios em $B = 60$ para 0,01 em $B = 80$ e zero em $B = 100$ (Tabela 6). A distância da Tabela 6 é média sobre todas as execuções da MP-EAVNS em cada nível de bateria; por isso, em $B = 80$, difere da Tabela 4, que condiciona a média às soluções viáveis. Depois dessa transição, a inviabilidade energética deixa de ser o gargalo principal.

TABELA 6 – Sensibilidade da MP-EAVNS à autonomia sob a política Gradual.


B	Viabilidade	Inviáveis médios	Distância	Atraso	Recargas
60	82,6 %	0,22	1.143,7	8,9	12,26
80	98,6 %	0,01	1.075,6	1,7	6,09
100	100,0 %	0,00	1.054,4	0,0	1,74

Fonte: Elaborado pelo autor (2026).

4.6 Custo Computacional

A Figura 5 cruza tempo de execução e qualidade. A MP-EAVNS custa em média 3,73 s por solução, contra 0,35 s do GRASP e 14,44 s da ALNS: cerca de 10,8 vezes mais lenta que o GRASP (mas com objetivo 36,0 % menor) e 3,9 vezes mais rápida que a ALNS, ainda produzindo rotas mais curtas em soluções viáveis (Tabela 4). As construtivas puras custam frações de milissegundo, ao preço da viabilidade (Tabela 3).

FIGURA 5 – Tempo médio por solução versus objetivo médio nos principais algoritmos.



Fonte: Elaborado pelo autor (2026).

5. CONCLUSÃO

Este artigo apresentou o PRMD-ER, uma extensão multi-período do E-VRPTW para roteamento de drones com estações disponibilizadas gradualmente. A MP-EAVNS foi avaliada nas 92 instâncias do *benchmark* E-VRPTW (9.936 execuções totais), contra heurísticas construtivas, GRASP, ALNS adaptada e três variantes reduzidas. A MP-EAVNS reduziu o objetivo penalizado em 36,0 % frente ao GRASP, atingiu 100 % de viabilidade sob a política Completa e produziu rotas 6,7 % mais curtas que a ALNS nesse regime; o estudo confirma que a herança entre períodos é o componente que mais contribui para o ganho.

O resultado central é que a disponibilização gradual preserva 98,6 % da viabilidade da política Completa e apresenta distância viável apenas 1,4 % superior à desse regime — a operação não precisa esperar pela infraestrutura total para se aproximar do melhor desempenho observado. Trabalhos futuros podem incorporar modelos energéticos mais realistas e tratar a disponibilização de estações como variável de decisão do planejamento.

REFERÊNCIAS

- Asghari, M. and Mirzapour Al-e hashem, S. M. J. (2021). Green vehicle routing problem: A state-of-the-art review. *International Journal of Production Economics*, 231:107899.
- Berbeglia, G., Cordeau, J.-F., and Laporte, G. (2010). Dynamic pickup and delivery problems. *European Journal of Operational Research*, 202(1):8–15.
- Cai, J., Zhu, Q., and Lin, Q. (2022). Variable neighborhood search for a new practical dynamic pickup and delivery problem. *Swarm and Evolutionary Computation*, 75:101182.
- Cai, J., Zhu, Q., Lin, Q., Ma, L., Li, J., and Ming, Z. (2023). A survey of dynamic pickup and delivery problems. *Neurocomputing*, 554:126631.
- Coelho, B. N., Coelho, V. N., Coelho, I. M., Ochi, L. S., Haghazadeh K., R., Zuidema, D., Lima, M. S. F., and da Costa, A. R. (2017). A multi-objective green UAV routing problem. *Computers & Operations Research*, 88:306–315.
- Dantzig, G. B. and Ramser, J. H. (1959). The truck dispatching problem. *Management Science*, 6(1):80–91.
- Ghorbani, E., Alinaghian, M., Gharehpetian, G. B., Mohammadi, S., and Perboli, G. (2020). A survey on environmentally friendly vehicle routing problem and a proposal of its classification. *Sustainability*, 12(21):9079.
- Goeke, D. (2019). E-VRPTW instances.
- Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598):671–680.
- Li, H. and Lim, A. (2001). A metaheuristic for the pickup and delivery problem with time windows. In *Proceedings of the 13th IEEE International Conference on Tools with Artificial Intelligence*, pages 160–167.
- Mladenović, N. and Hansen, P. (1997). Variable neighborhood search. *Computers & Operations Research*, 24(11):1097–1100.
- Pillac, V., Gendreau, M., Guéret, C., and Medaglia, A. L. (2013). A review of dynamic vehicle routing problems. *European Journal of Operational Research*, 225(1):1–11.
- Psaraftis, H. N. (1988). Dynamic vehicle routing problems. In Golden, B. L. and Assad, A. A., editors, *Vehicle Routing: Methods and Studies*, pages 223–248. North-Holland.
- Raivi, A. M., Huda, S. M. A., Alam, M. M., and Moh, S. (2023). Drone routing for drone-based delivery systems: A review of trajectory planning, charging, and security. *Sensors*, 23(3):1463.

- Ribeiro, R. G., Carvalho Júnior, J. R. C., Cota, L. P., Euzébio, T. A. M., and Guimarães, F. G. (2020). Unmanned aerial vehicle location routing problem with charging stations for belt conveyor inspection system in the mining industry. *IEEE Transactions on Intelligent Transportation Systems*, 21(10):4186–4195.
- Ropke, S. and Pisinger, D. (2006). An adaptive large neighborhood search heuristic for the pickup and delivery problem with time windows. *Transportation Science*, 40(4):455–472.
- Savelsbergh, M. W. P. and Sol, M. (1995). The general pickup and delivery problem. *Transportation Science*, 29(1):17–29.
- Schneider, M., Stenger, A., and Goeke, D. (2014). The electric vehicle-routing problem with time windows and recharging stations. *Transportation Science*, 48(4):500–520.
- Shi, J., Mao, H., Zhou, Z., and Zheng, L. (2023). Adaptive large neighborhood search algorithm for the unmanned aerial vehicle routing problem with recharging. *Applied Soft Computing*, 147:110831.
- Solomon, M. M. (1987). Algorithms for the vehicle routing and scheduling problems with time window constraints. *Operations Research*, 35(2):254–265.
- Stamadianos, T., Kyriakakis, N. A., Marinaki, M., and Marinakis, Y. (2023). Routing problems with electric and autonomous vehicles: Review and potential for future research. *Operations Research Forum*, 4:46.
- Vichitkunakorn, P., Emde, S., Masae, M., Glock, C. H., and Grosse, E. H. (2024). Locating charging stations and routing drones for efficient automated stocktaking. *European Journal of Operational Research*, 316(3):1129–1145.
- Zhou, Y., Kong, L., Yan, L., Liu, Y., and Wang, H. (2024). A memetic algorithm for a real-world dynamic pickup and delivery problem. *Memetic Computing*, 16:203–217.